VISUALIZACION DE DATOS · PROYECTO FINAL · FUSM

Guía Cardio360

Cómo abrir, repetir y verificar el proyecto de predicción de riesgo cardiovascular a partir de la carpeta `C:\Cardio360`: datos, tres cuadernos, tablero interactivo e informe.

Autor	Omar Libardo Acelas Angulo
Tutor	Sergio Lara
Institución	Fundación Universitaria San Mateo · Bogotá
Fecha	Octubre de 2026
Sitio del proyecto	omarli-360.github.io/cardio360
Repositorio	github.com/OmarLi-360/cardio360

1. Qué contiene la carpeta

Descargue el proyecto desde github.com/OmarLi-360/cardio360 (botón **Code → Download ZIP**) o use el `Cardio360.zip` entregado. Descomprímalo en `C:\` y, si la carpeta se llama `cardio360-main`, renómbrela a `Cardio360`. Debe quedar así:

```
C:\Cardio360\
├── index.html                          portada del sitio web
├── GUIA_Cardio360.pdf                  esta guía
├── LEEME.txt                           resumen de una página
├── requirements.txt                    librerías de Python necesarias
├── construir_tablero.py                regenera el tablero desde los resultados
├── datos\
│   ├── cardio_train.csv                datos originales (70.000 registros, separador ;)
│   └── cardio_depurado.csv             datos limpios (68.512 registros, listo para Excel)
├── cuadernos\
│   ├── 01_EDA_y_Limpieza.ipynb         análisis exploratorio y limpieza
│   ├── 02_Modelado_y_Evaluacion.ipynb modelos, curvas, umbral, SHAP, equidad
│   └── 03_Reduccion_Dimensionalidad.ipynb  PCA, t-SNE, UMAP
├── resultados\                         eda.json, modelos.json, latente.json
├── tablero\
│   ├── index.html                      tablero, versión web (la publica GitHub Pages)
│   └── tablero_riesgo_cardiovascular.html   tablero interactivo (sin internet)
├── recursos\                           plantilla del tablero y librería Plotly
├── assets\                             ícono e imagen para compartir el sitio
└── informe\                            informe ejecutivo (PDF y Word)
```

Arquitectura. Los cuadernos **calculan** y guardan sus resultados en `resultados\`. El tablero **observa**: `construir_tablero.py` une esos resultados con la plantilla en un único archivo HTML. El tablero nunca reentrena modelos.

2. Tres formas de usarlo

`A · 1 minuto`

Solo ver los resultados

Sin instalar nada. Abre el tablero, el informe y los cuadernos ya ejecutados.

`B · 15 minutos`

Repetir en Google Colab

Sin instalar nada. Solo requiere una cuenta de Google.

`C · 30 minutos`

Repetir en el computador

Instala Python y las librerías. Funciona sin internet una vez instalado.

3. Ruta A: ver los resultados

1. Abra `tablero\tablero_riesgo_cardiovascular.html` con doble clic. Se abre en el navegador (Chrome, Edge o Firefox) y funciona sin internet.
2. Recorra las pestañas. Las tres más reveladoras son **Umbral y calibración** (mueva el umbral), **Espacio latente** (haga clic en un paciente para ver su explicación) y **Equidad**.
3. Abra el informe en `informe\`. Los cuadernos ya traen sus gráficos: se pueden ver sin ejecutarlos subiéndolos a Colab (paso B1) o en VS Code o Jupyter.

4. Ruta B: repetir en Google Colab

1. En el sitio omarli-360.github.io/cardio360, pulse **Abrir en Colab** en el cuaderno 01 (se abre con una cuenta de Google). Otra opción: en colab.research.google.com, elija **Archivo → Subir cuaderno** y suba `cuadernos\01_EDA_y_Limpieza.ipynb`.
2. Elija **Entorno de ejecución → Ejecutar todas**. El cuaderno instala lo que falte y descarga los datos del repositorio del proyecto en GitHub; no hay que subirlos. Si Colab muestra un aviso de que el cuaderno no es de Google, elija **Ejecutar de todos modos**.
3. Al final, Colab descarga al computador los archivos de resultados (`eda.json` y `cardio_depurado.csv`). Si el navegador pregunta, permita las descargas múltiples.
4. Repita los pasos 1 a 3 con el cuaderno `02` (unos 4 minutos) y luego con el `03` (unos 5 minutos). Se descargan `modelos.json` y `latente.json`.
5. Para ver el tablero con sus propios resultados, copie los tres `.json` descargados en `C:\Cardio360\resultados\` (reemplace los existentes) y siga la sección 6. Necesita Python, pero no las librerías de la ruta C.

> Si GitHub no está disponible, suba también `datos\cardio_train.csv` al panel **Archivos** de Colab (icono de carpeta a la izquierda) antes de ejecutar: el cuaderno usa primero el archivo local.

5. Ruta C: repetir en el computador (Windows)

5.1 Instalar Python (una sola vez)

1. Descargue Python 3.12 desde python.org/downloads/windows. En el instalador marque **Add python.exe to PATH**. Se recomienda Python 3.10, 3.11 o 3.12.

2. Abra el **Símbolo del sistema** (tecla `Windows`, escriba `cmd`, `Enter`) y compruebe la instalación:

```
py --version
```

5.2 Preparar el entorno del proyecto (una sola vez)

En el mismo Símbolo del sistema, ejecute línea por línea:

```
cd C:\Cardio360
py -3.12 -m venv .venv
.venv\Scripts\activate
python -m pip install --upgrade pip
pip install -r requirements.txt
```

La instalación tarda de 3 a 8 minutos. Al terminar, la línea de comandos empieza con `(.venv)`. Si tiene otra versión, cambie `-3.12` por la suya (por ejemplo `-3.11`).

5.3 Ejecutar los cuadernos

1. Con el entorno activo, abra Jupyter:

   ```
   jupyter lab
   ```

   Se abre una pestaña del navegador con la carpeta del proyecto.

2. Entre a `cuadernos` y abra `01_EDA_y_Limpieza.ipynb`. Elija **Run → Run All Cells**. Termina en menos de un minuto.

3. Repita con `02_Modelado_y_Evaluacion.ipynb` (unos 4 minutos) y `03_Reduccion_Dimensionalidad.ipynb` (unos 5 minutos), en ese orden.

Los cuadernos detectan que están dentro de `C:\Cardio360`: leen `datos\cardio_train.csv`, escriben en `resultados\` y regeneran `datos\cardio_depurado.csv`. No necesitan internet.

> Para volver otro día: abra `cmd`, ejecute `cd C:\Cardio360`, luego `.venv\Scripts\activate` y `jupyter lab`. También puede abrir la carpeta en VS Code con la extensión de Jupyter y elegir el intérprete de `.venv`.

---

6. Reconstruir el tablero

Después de ejecutar los cuadernos (ruta B o C), regenere el tablero con sus propios resultados:

```
cd C:\Cardio360
py construir_tablero.py
```

El script solo usa la biblioteca estándar de Python, así que no requiere el entorno de la ruta C. Escribe dos versiones: `tablero\tablero_riesgo_cardiovascular.html`, con la librería de gráficos incluida para usar sin internet (ábralo con doble clic), y `tablero\index.html`, la versión liviana que publica GitHub Pages.

7. Cómo comprobar que se repitió bien

Con la semilla fija (42), estos valores deben coincidir. Pueden variar en el tercer decimal si cambian las versiones de las librerías.

DÓNDE	QUÉ MIRAR	VALOR ESPERADO
Cuaderno 01	Registros tras la limpieza	68.512 de 70.000 (97,9 %)
Cuaderno 01	Sistólicas que terminan en 0	97,1 %
Cuaderno 02	Hiperparámetros elegidos	C ≈ 0,018 · profundidad 8 (RF) · profundidad 3 (XGBoost)
Cuaderno 02	AUC-ROC en prueba	0,794 (log.) · 0,800 (RF) · 0,803 (XGBoost)
Cuaderno 02	Umbral de tamizaje	0,33 · sensibilidad 0,853 · 999 enfermos no detectados
Cuaderno 03	Confiabilidad t-SNE / UMAP / PCA	0,991 / 0,982 / 0,745

8. Diccionario de `cardio_depurado.csv`

68.512 filas y 16 columnas. Formato pensado para Excel en español: separador `;`, decimales con coma, UTF-8. Se abre con doble clic en Excel. En Python:

```
pd.read_csv("datos/cardio_depurado.csv", sep=";", decimal=",")
```

COLUMNA	DESCRIPCIÓN	VALORES
`id`	Identificador del registro en el archivo original	Entero
`edad_dias`	Edad tal como viene en la fuente	Días
`edad_anios`	Edad en años (días / 365,25)	29,6 a 64,9
`sexo`	Sexo del paciente	Mujer, Hombre
`altura_cm`, `peso_kg`	Altura y peso	130–210 cm · 35–180 kg
`imc`	Índice de masa corporal: peso / altura²	13–60 kg/m²
`sistolica_mmhg`, `diastolica_mmhg`	Presión arterial	80–250 · 40–160 mmHg
`categoria_pa`	Categoría de presión según la guía ACC/AHA 2017	Normal, Elevada, HTA estadio 1, HTA estadio 2, Crisis hipertensiva
`colesterol`, `glucosa`	Nivel reportado en el examen	1 normal · 2 sobre lo normal · 3 muy sobre lo normal
`fuma`, `alcohol`, `activo`	Hábitos autorreportados	0 no · 1 sí
`cardio`	Presencia de enfermedad cardiovascular (variable objetivo)	0 no · 1 sí

Las siete reglas de limpieza y su justificación clínica están en la sección 3 del cuaderno 01.

9. Problemas frecuentes

SÍNTOMA	SOLUCIÓN
`'py' no se reconoce como un comando`	Reinstale Python marcando **Add python.exe to PATH**, o use `python` en lugar de `py`.
PowerShell no deja ejecutar `activate`	Use el Símbolo del sistema (`cmd`), no PowerShell.
Falla la instalación de `shap` o `umap-learn`	Use Python 3.10, 3.11 o 3.12. Las versiones más nuevas pueden no tener aún paquetes compilados.
`Falta resultados\...json` al construir el tablero	Ejecute antes los tres cuadernos, o copie los JSON descargados de Colab en `resultados\`.
Excel muestra todo en una sola columna	El equipo tiene configurada la coma como separador de listas. Use **Datos → Desde texto/CSV** y elija punto y coma como delimitador.
Colab no descarga los archivos	Permita las descargas múltiples en el navegador, o descárguelos desde el panel **Archivos** (carpeta `resultados`).

10. Cibergrafía

Normas APA, 7.ª edición. Enlaces comprobados el 19 de octubre de 2026. La herramienta de IA se cita según APA Style (septiembre de 2025).

Anthropic. (2026). *Claude* (claude-opus-5-5) [Modelo de lenguaje grande]. https://claude.ai

caravanuden. (s. f.). *cardio* [Repositorio de GitHub; copia de cardio_train.csv]. https://github.com/caravanuden/cardio

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Google. (s. f.). *Google Colab* [Entorno de cuadernos en la nube]. https://colab.research.google.com/

Lundberg, S. M., Erion, G., Chen, H., y otros. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence, 2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

McAdoo, T., Denneny, S., & Lee, C. (2025, 9 de septiembre). Citing generative AI in APA Style: Part 1—Reference formats. *APA Style Blog*. https://apastyle.apa.org/blog/cite-generative-ai-references

McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform manifold approximation and projection for dimension reduction* [Preimpresión]. arXiv. https://arxiv.org/abs/1802.03426

Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596

pandas development team. (2026). *pandas documentation* (versión 3.0.6). https://pandas.pydata.org/docs/

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Plotly. (s. f.). *Plotly JavaScript open source graphing library*. https://plotly.com/javascript/

scikit-learn developers. (s. f.-a). *Probability calibration* (versión 1.9.1). https://scikit-learn.org/stable/modules/calibration.html

scikit-learn developers. (s. f.-b). *Validation curves: Plotting scores to evaluate models* (versión 1.9.1). https://scikit-learn.org/stable/modules/learning_curve.html

SHAP developers. (s. f.). *Welcome to the SHAP documentation*. https://shap.readthedocs.io/en/latest/

Ulianova, S. (s. f.). *Cardiovascular Disease dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset

UMAP developers. (s. f.). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction* [Documentación]. https://umap-learn.readthedocs.io/en/latest/

van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research, 9*, 2579–2605. https://www.jmlr.org/papers/v9/vandermaaten08a.html

Wattenberg, M., Viégas, F., & Johnson, I. (2016). How to use t-SNE effectively. *Distill, 1*(10). https://doi.org/10.23915/distill.00002

Whelton, P. K., Carey, R. M., Aronow, W. S., y otros. (2017). 2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA guideline for the prevention, detection, evaluation, and management of high blood pressure in adults. *Hypertension*. https://doi.org/10.1161/HYP.0000000000000065

XGBoost developers. (2026). *XGBoost documentation* (versión 3.4.2). https://xgboost.readthedocs.io/en/stable/

Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer, 3*, 32–35. https://pubmed.ncbi.nlm.nih.gov/15405679/

11. Declaración de uso de inteligencia artificial

El proyecto se desarrolló con apoyo de Claude (Anthropic, 2026), un modelo de lenguaje grande. Claude ayudó a localizar y verificar los datos, a escribir el código de los cuadernos y del tablero, a redactar el informe y a comprobar la cibergrafía. El autor definió el alcance y validó las decisiones del análisis, y es responsable del contenido entregado.