Informe ejecutivo · Predicción de riesgo cardiovascular

Oct 19, 2026 · @Omar Acelas

Autor: Omar Libardo Acelas Angulo · **Tutor:** Sergio Lara · Visualización de Datos · Fundación Universitaria San Mateo

Resumen ejecutivo

Con 14 variables de un examen médico de rutina, la enfermedad cardiovascular (ECV) se puede anticipar con un AUC-ROC de **0,803**. El modelo es XGBoost, probado en 13.703 pacientes que nunca vio. El límite no está en el algoritmo ni en la cantidad de datos: lo ponen las variables disponibles.

Problema. Proyecto final de Visualización de Datos. Se pidió seleccionar un conjunto de datos, explorarlo con visualizaciones básicas, entrenar un modelo de aprendizaje automático, visualizar su desempeño con curvas de aprendizaje y validación, aplicar reducción de dimensionalidad y construir una visualización interactiva de los resultados.

Enfoque. Tres cuadernos de Google Colab calculan y exportan sus resultados; un tablero HTML interactivo los presenta. Además de lo exigido, se agregaron cuatro análisis que responden *por qué* decide el modelo y *para quién* falla:

- explicabilidad con SHAP;
- elección del umbral con criterio clínico;
- análisis de equidad por sexo y edad, con su ficha del modelo (*Model Card*);
- un simulador de riesgo.

Resultados clave

Pregunta	Respuesta
¿Qué tan bien se predice?	AUC-ROC de 0,803 con XGBoost; la regresión logística logra 0,794 y Random Forest 0,800.
¿Qué la predice?	La presión sistólica, con un impacto 2,9 veces mayor que el de la edad, que es la segunda variable.
¿Qué umbral usar?	0,33 para tamizaje. Con él, los enfermos no detectados bajan de 2.122 a 999 (−53 %).

Pregunta	Respuesta
¿Es equitativo?	Por sexo, sí. Por edad, no con un umbral único: el modelo alerta al 92,5 % de las personas de 55 a 65 años y pierde al 37 % de los enfermos de 30 a 44.
¿Se separan las clases al reducir dimensiones?	No: ya se superponen en las 14 dimensiones originales, y eso explica el techo de AUC ≈ 0,80.

Recomendación. El modelo sirve como herramienta educativa y, como máximo, para **priorizar** a quién hacer un tamizaje más completo. No sirve para diagnosticar. Para superar el techo actual hacen falta mejores variables (antecedentes familiares, perfil lipídico detallado, tratamientos), no más registros.

Sitio del proyecto: omarli-360.github.io/cardio360 · Tablero interactivo: omarli-360.github.io/cardio360/tablero · Repositorio: github.com/OmarLi-360/cardio360.

Datos y limpieza

Se conservaron **68.512 de 70.000 registros (97,9 %)**. Los 1.488 eliminados no eran casos raros sino imposibles: presiones negativas, diastólicas de 11.000 mmHg o mayores que la sistólica.

Fuente. El conjunto es el Cardiovascular Disease dataset de Svetlana Ulianova (Kaggle). Reúne exámenes de adultos de 30 a 65 años con 11 variables (5 objetivas, 3 del examen médico y 3 autorreportadas) y la etiqueta `cardio`. Las clases están balanceadas (50/50) y no hay valores nulos. Los cuadernos leen una copia pública en GitHub, verificada idéntica byte a byte (MD5) a una segunda copia independiente.

Criterio de limpieza. Se usó criterio clínico y no estadístico. Un filtro por rango intercuartílico habría eliminado hipertensos reales, que son justo los pacientes que interesan. Las reglas se aplicaron en este orden:

Regla	Registros eliminados	Justificación
Diastólica fuera de 40–160 mmHg	1.007	Valores como 0 o 1.000 son errores de captura
Sistólica fuera de 80–250 mmHg	247	Valores como −150 o 16.020 son errores de digitación
Altura fuera de 130–210 cm	89	Incompatible con adultos (55 cm, 250 cm)

Regla	Registros eliminados	Justificación
Diastólica ≥ sistólica	82	Fisiológicamente imposible; probablemente columnas invertidas
Duplicados	24	El mismo paciente registrado dos veces
IMC fuera de 13–60	20	Combinación altura-peso imposible
Peso fuera de 35–180 kg	19	Extremos implausibles

Variables derivadas. Se calcularon la edad en años (el dato original viene en días), el IMC y la categoría de presión arterial según la guía ACC/AHA 2017. El colesterol y la glucosa (niveles 1, 2 y 3) se codificaron *one-hot*, porque son categorías clínicas y no distancias.

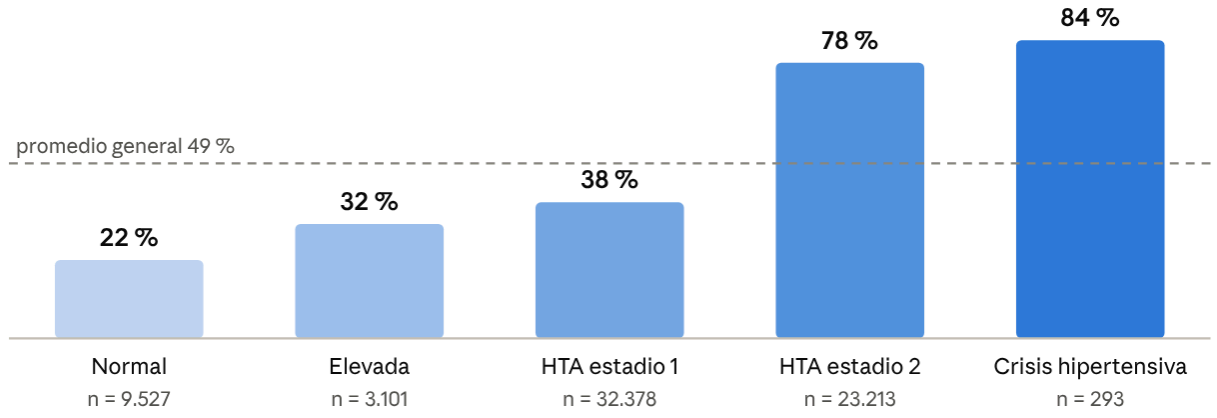
Hallazgo de calidad: preferencia de dígito. El **97,1 %** de las presiones sistólicas termina en cero, y el 40 % vale exactamente 120 mmHg. La presión se registró redondeada, así que se comporta casi como una variable ordinal. Es un límite del dato que el modelo hereda.

Análisis exploratorio

La presión arterial es la señal más fuerte del conjunto: la proporción de ECV crece con cada categoría de la guía ACC/AHA, en una clara relación dosis-respuesta.

La proporción con ECV sube de 22 % a 84 % según la presión arterial

% de pacientes con ECV por categoría de presión (ACC/AHA 2017) · 68.512 pacientes



Cuaderno 01 · 68.512 pacientes limpios · clasificación ACC/AHA 2017

Otros hallazgos del análisis exploratorio:

- **Edad.** La prevalencia sube del 24 % entre los 30 y 39 años al 67 % entre los 60 y 65, con un patrón casi idéntico en hombres y mujeres.

- **Colesterol.** El 76 % de quienes tienen colesterol muy alto presenta ECV, frente al 44 % con colesterol normal. La glucosa sigue la misma dirección, con menos fuerza.
- **Hábitos autorreportados.** Casi no diferencian a los grupos: los fumadores muestran incluso una tasa levemente menor (47 % frente a 50 %). Las explicaciones probables son el subreporte y la confusión con el sexo (fumar y ser hombre correlacionan 0,34).
- **Correlaciones.** La sistólica es la variable más asociada con la ECV (r = 0,43), seguida de la diastólica (0,34) y la edad (0,24). Hay variables redundantes: peso e IMC (0,87) y sistólica y diastólica (0,73). Esto afecta la lectura de los coeficientes de la regresión logística, no su capacidad predictiva.

Modelado y diagnóstico de ajuste

Los tres modelos rinden casi igual: entre el mejor y el peor hay apenas 0,009 de AUC. Las curvas de aprendizaje muestran que más datos no cambiarían este resultado.

Diseño. Partición estratificada 80/20 con semilla fija (42). Todos los hiperparámetros se eligieron con validación cruzada estratificada de 5 pliegues sobre el 80 % de entrenamiento. El 20 % de prueba se usó una sola vez, en la evaluación final.

Curvas de validación. Para cada modelo se varió su hiperparámetro de complejidad y se tomó el valor más simple a menos de 0,001 del mejor AUC de validación:

- **Regresión logística:** C ≈ 0,018. A partir de ahí la curva se aplana y entrenamiento y validación coinciden: no hay sobreajuste.
- **Random Forest:** profundidad 8. Más allá, el entrenamiento sube hasta 0,90 mientras la validación cae.
- **XGBoost:** profundidad 3. Con más profundidad, el entrenamiento llega a 0,97 y la validación cae. Que basten árboles tan pequeños indica relaciones simples, con pocas interacciones.

Curvas de aprendizaje. En los tres modelos, la curva de validación se aplana hacia los 10.000–15.000 pacientes, y la brecha final con la de entrenamiento es mínima: 0,000 en la logística, 0,007 en XGBoost y 0,014 en Random Forest. Con 44.000 pacientes de entrenamiento, el techo lo pone la información que traen las variables, no la cantidad de registros.

Evaluación en prueba (13.703 pacientes, umbral 0,50):

Modelo	AUC-ROC	AUC-PR	Exactitud	Sensibilidad	Especificidad	Brier
XGBoost	0,803	0,787	0,736	0,687	0,783	0,180
Random Forest	0,800	0,782	0,734	0,663	0,805	0,182
Regresión logística	0,794	0,775	0,728	0,667	0,787	0,186

La validación cruzada confirma el orden con poca variación entre pliegues: AUC de 0,801 ± 0,004 para XGBoost, 0,798 ± 0,003 para Random Forest y 0,791 ± 0,003 para la logística.

Umbral, calibración, explicabilidad y equidad

El hallazgo más importante está en esta sección: un AUC global de 0,80 esconde un desempeño muy desigual según la edad del paciente.

Umbral de decisión. En tamizaje, un enfermo que no se detecta cuesta más que un examen adicional. Se compararon tres criterios con XGBoost:

Criterio	Umbral	Sensibilidad	Especificidad	Enfermos no detectados	Falsas alarmas
Por defecto	0,50	0,687	0,783	2.122	1.500
Youden	0,48	0,709	0,763	1.971	1.639
Tamizaje (recomendado)	**0,33**	**0,853**	**0,543**	**999**	**3.161**

El umbral de tamizaje garantiza una sensibilidad ⩾ 85 %. Reduce en un 53 % los enfermos no detectados, a cambio de duplicar las falsas alarmas.

Calibración. Las curvas de los tres modelos siguen la diagonal (Brier entre 0,180 y 0,186). Sus probabilidades se pueden leer como riesgos, y por eso tiene sentido el porcentaje que muestra el simulador del tablero.

Explicabilidad. SHAP en XGBoost y los coeficientes estandarizados de la regresión logística coinciden en el orden de importancia:

1. La presión sistólica (|SHAP| medio de 0,79).
2. La edad (0,27).
3. El colesterol muy alto (0,17).

En el gráfico de dependencia, el aporte de la sistólica cambia de signo cerca de **130 mmHg**: el modelo redescubrió el umbral de hipertensión estadio 1 de la guía ACC/AHA sin que se le indicara.

Hay tres señales contraintuitivas: la glucosa muy alta, fumar y el alcohol reducen levemente el riesgo predicho. No son efectos causales. Las explicaciones probables son el subreporte de los hábitos, pacientes que ya están en tratamiento y la correlación de la glucosa con el colesterol (0,48), que se lleva el efecto.

Equidad (XGBoost, umbral 0,33):

Grupo	Pacientes	AUC	Sensibilidad	Especificidad	Tasa de alerta
Mujeres	8.902	0,806	0,855	0,549	0,649
Hombres	4.801	0,796	0,849	0,532	0,659
30–44 años	1.917	0,823	0,628	0,893	0,256
45–54 años	5.562	0,790	0,731	0,714	0,485
55–65 años	6.224	0,751	0,965	0,136	0,925

Por sexo hay paridad. Por edad, el modelo se apoya tanto en ella que un joven enfermo no parece enfermo y un mayor sano sí lo parece: alerta a casi todos los de 55 a 65 años y pierde a más de un tercio de los enfermos de 30 a 44. Ningún umbral único equilibra a los tres grupos. Las mitigaciones posibles son umbrales por grupo de edad o recalibración por subgrupo.

Reducción de dimensionalidad

Al comprimir las 14 variables en 2 dimensiones, los pacientes con y sin ECV siguen mezclados. No es un defecto de la técnica: ya están mezclados en el espacio original.

Se aplicaron tres técnicas a 3.000 pacientes de prueba, con las variables estandarizadas usando solo los datos de entrenamiento:

- **PCA** (lineal; conserva la varianza global).
- **t-SNE** (perplejidad 30) y **UMAP** (15 vecinos), no lineales, que conservan los vecindarios locales.

Espacio	Confiabilidad (k = 15)	AUC de k-NN
14 dimensiones originales	1,000	0,779
t-SNE	0,991	0,760
UMAP	0,982	0,758
PCA	0,745	0,751

Lectura de PCA. Los dos primeros componentes explican solo el 32 % de la varianza, y hacen falta 8 de 14 para llegar al 80 %:

- **PC1, carga cardiometabólica:** peso, IMC y presiones. Es el eje que más se alinea con la enfermedad.
- **PC2, eje del sexo:** sexo, altura, tabaco y alcohol.
- **PC3, eje metabólico:** contrasta el colesterol y la glucosa muy altos con los altos.

Lectura de t-SNE y UMAP. Las islas que se forman corresponden a combinaciones de variables categóricas (sexo, colesterol, glucosa, tabaco y alcohol), no a subtipos de enfermedad. Dentro de cada isla, la presión y la probabilidad predicha varían como un degradado. Al colorear por el resultado del modelo, los errores se reparten dentro de cada isla, en la zona donde las clases se mezclan. También se mostró cómo cambian las proyecciones con la perplejidad (5, 30 y 100) y con el número de vecinos (5, 15 y 50), para evitar sobreinterpretarlas.

Conclusión. El k-NN en 2D pierde solo entre 0,02 y 0,03 de AUC frente a las 14 dimensiones. La visualización y el modelo cuentan la misma historia: las clases se superponen, y por eso el techo está en un AUC cercano a 0,80.

Visualización interactiva

El Tablero de Riesgo Cardiovascular reúne todos los resultados en una página web que se abre en cualquier navegador, de escritorio o móvil. Lee los JSON que exportan los cuadernos y nunca reentrena: los cuadernos calculan, el tablero observa. Está publicado en GitHub Pages, junto con una portada del proyecto, los cuadernos que se abren en Colab y las descargas.

Pestaña	Qué se puede hacer
Resumen	Leer los indicadores clave y los cinco hallazgos principales
Datos	Ver el embudo de limpieza y la presión cruda; filtrar las distribuciones por variable, sexo, edad y colesterol; ver la proporción de ECV por dimensión y la matriz de correlación
Modelos	Comparar métricas, estabilidad por pliegue, curvas ROC y precisión-sensibilidad; alternar las curvas de validación y de aprendizaje por modelo

Pestaña	Qué se puede hacer
Umbral y calibración	Mover el umbral y ver en vivo la matriz de confusión y las métricas; saltar a los criterios por defecto, Youden o tamizaje; ver la calibración
Espacio latente	Alternar PCA, t-SNE y UMAP; colorear por resultado, clase, riesgo, presión, edad, colesterol o sexo; al hacer clic en un paciente, ver su explicación SHAP individual
Explicabilidad	Comparar la importancia SHAP con los coeficientes de la logística
Equidad	Mover el umbral y ver sensibilidad, especificidad y tasa de alerta por sexo y edad
Simulador	Ajustar el perfil de un paciente y ver su riesgo estimado y qué lo empuja
Ficha del modelo	Consultar el uso previsto, los límites, la equidad y las consideraciones éticas

El umbral se comparte entre pestañas: si se mueve en una, cambia en todas. El simulador usa la regresión logística porque su fórmula cabe en el navegador. Su resultado se verificó contra scikit-learn y coincide hasta la sexta cifra decimal (95,7130 % en ambos). La paleta asigna un color fijo a cada significado (azul para sin ECV o falsa alarma, naranja para con ECV o caso no detectado) y funciona en modo claro y oscuro.

Limitaciones, ética y recomendaciones

El modelo es válido como herramienta educativa y de priorización, no como instrumento diagnóstico.

Limitaciones

- No se documentan el origen geográfico ni el periodo de recolección de los datos, así que no se sabe a qué población se generaliza.
- La presión arterial se registró redondeada (el 97 % termina en cero).
- Los hábitos (tabaco, alcohol, actividad) son autorreportados y probablemente están subestimados.
- Faltan variables clínicas clave: antecedentes familiares, perfil lipídico detallado y tratamientos en curso.
- Las asociaciones que aprende el modelo no son causales.

Consideraciones éticas. Un falso negativo puede retrasar la atención de un paciente; un falso positivo genera ansiedad y costos. Con un umbral único, la carga de esos errores no se reparte igual entre los grupos de edad. Toda decisión clínica corresponde a un profesional de la salud.

Recomendaciones

1. Para tamizaje, usar el umbral de 0,33 y no el de 0,50 que viene por defecto.
2. Evaluar umbrales diferenciados por grupo de edad, o recalibrar por subgrupo, antes de cualquier uso real.
3. Para superar el AUC de 0,80, invertir en mejores variables y no en más registros.
4. Revalidar el modelo antes de aplicarlo a poblaciones colombianas o fuera del rango de 30 a 65 años.

Entregables

Entregable (carpeta `C:\Cardio360`)	Contenido
Sitio del proyecto	Portada, tablero, cuadernos que se abren en Colab y descargas, en GitHub Pages
Repositorio en GitHub	La carpeta completa, versionada y descargable en ZIP
`GUIA_Cardio360.pdf`	Paso a paso para ver, repetir y reconstruir el proyecto
`cuadernos\01_EDA_y_Limpieza.ipynb`	Perfil, reglas de limpieza, variables derivadas, distribuciones, prevalencias, correlaciones y exportación del CSV depurado
`cuadernos\02_Modelado_y_Evaluacion.ipynb`	Tres modelos, curvas de validación y aprendizaje, ROC/PR, calibración, umbral, SHAP, equidad y ficha del modelo
`cuadernos\03_Reduccion_Dimensionalidad.ipynb`	PCA, t-SNE y UMAP, sensibilidad a hiperparámetros, métricas de confiabilidad y vista interactiva con Plotly
`datos\cardio_depurado.csv`	68.512 pacientes limpios con 16 columnas, listo para Excel en español

Entregable (carpeta `C:\Cardio360`)	Contenido
`tablero\tablero_riesgo_cardiovascular.html`	Visualización interactiva; se abre con doble clic y funciona sin internet
`construir_tablero.py`	Regenera el tablero (versión web y sin internet) a partir de los resultados de los cuadernos
Este informe	Síntesis ejecutiva de lo realizado

El proyecto se puede repetir de dos formas: en Google Colab, sin instalar nada, o en el computador con Python 3.10 a 3.12. En ambos casos, los cuadernos se ejecutan de punta a punta (Ejecutar todas) en menos de 12 minutos en total. Leen los datos de la carpeta `datos` o, si no los encuentran, de GitHub, y usan una sola semilla (42), así que los resultados son reproducibles. La guía incluida en la carpeta describe cada paso.

Cibergrafía

Normas APA, 7.ª edición. Todos los enlaces se comprobaron el 19 de octubre de 2026. La herramienta de IA se cita según la guía de APA Style de septiembre de 2025.

- Anthropic. (2026). *Claude* (claude-opus-5-5) [Modelo de lenguaje grande]. https://claude.ai
- caravanuden. (s. f.). *cardio* [Repositorio de GitHub; copia de cardio_train.csv]. https://github.com/caravanuden/cardio
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785
- Google. (s. f.). *Google Colab* [Entorno de cuadernos en la nube]. https://colab.research.google.com/
- Lundberg, S. M., Erion, G., Chen, H., y otros. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence, 2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*. https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

- McAdoo, T., Denneny, S., & Lee, C. (2025, 9 de septiembre). Citing generative AI in APA Style: Part 1—Reference formats. *APA Style Blog*. https://apastyle.apa.org/blog/cite-generative-ai-references
- McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform manifold approximation and projection for dimension reduction* [Preimpresión]. arXiv. https://arxiv.org/abs/1802.03426
- Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model cards for model reporting. En *Proceedings of the Conference on Fairness, Accountability, and Transparency* (pp. 220–229). ACM. https://doi.org/10.1145/3287560.3287596
- pandas development team. (2026). *pandas documentation* (versión 3.0.6). https://pandas.pydata.org/docs/
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html
- Perplexity AI. (2026). *Perplexity* [Modelo de lenguaje grande]. https://www.perplexity.ai/
- Plotly. (s. f.). *Plotly JavaScript open source graphing library*. https://plotly.com/javascript/
- scikit-learn developers. (s. f.-a). *Probability calibration* (versión 1.9.1). https://scikit-learn.org/stable/modules/calibration.html
- scikit-learn developers. (s. f.-b). *Validation curves: Plotting scores to evaluate models* (versión 1.9.1). https://scikit-learn.org/stable/modules/learning_curve.html
- SHAP developers. (s. f.). *Welcome to the SHAP documentation*. https://shap.readthedocs.io/en/latest/
- Ulianova, S. (s. f.). *Cardiovascular Disease dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/sulianova/cardiovascular-disease-dataset
- UMAP developers. (s. f.). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction* [Documentación]. https://umap-learn.readthedocs.io/en/latest/
- van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research, 9*, 2579–2605. https://www.jmlr.org/papers/v9/vandermaaten08a.html
- Wattenberg, M., Viégas, F., & Johnson, I. (2016). How to use t-SNE effectively. *Distill, 1*(10). https://doi.org/10.23915/distill.00002

- Whelton, P. K., Carey, R. M., Aronow, W. S., y otros. (2017). 2017 ACC/AHA/AAPA/ABC/ACPM/AGS/APhA/ASH/ASPC/NMA/PCNA guideline for the prevention, detection, evaluation, and management of high blood pressure in adults. *Hypertension*. https://doi.org/10.1161/HYP.0000000000000065
- XGBoost developers. (2026). *XGBoost documentation* (versión 3.4.2). https://xgboost.readthedocs.io/en/stable/
- Youden, W. J. (1950). Index for rating diagnostic tests. *Cancer, 3*, 32–35. https://pubmed.ncbi.nlm.nih.gov/15405679/

Uso de inteligencia artificial y responsabilidad de la autoría

El proyecto se desarrolló con el apoyo de dos herramientas de inteligencia artificial, Perplexity (Perplexity AI, 2026) y Claude (Anthropic, 2026), modelos de lenguaje grande utilizados como herramientas de asistencia durante distintas etapas del proceso. Su participación incluyó la búsqueda y verificación de fuentes de información, el apoyo en la construcción del código de los cuadernos de análisis y del tablero de visualización, la revisión y corrección de la redacción del informe y la comprobación de las referencias bibliográficas y la cibergrafía.

El autor asumió la responsabilidad intelectual y metodológica del proyecto, que incluye el área y la problemática poblacional, la definición del problema de estudio, la formulación de los objetivos, la elaboración del plan de trabajo, la selección y justificación del conjunto de datos de carácter médico y la delimitación de las variables relevantes para el análisis. En esa misma línea, mediante la estrategia de Junta Técnica (una habilidad creada por el autor dentro de Claude para desarrollar ideas, construir soluciones y ejecutar proyectos evitando iteraciones ociosas e infructuosas, y optimizando los recursos más costosos: el tiempo humano y el procesamiento de IA), el autor definió los criterios de interpretación, la pertinencia de los procedimientos analíticos y la lectura de los resultados obtenidos, priorizando el estudio de los eventos de salud, sus patrones de comportamiento, su distribución y las posibles asociaciones entre las variables clínicas y epidemiológicas disponibles.

La utilización de Claude constituyó un valioso apoyo técnico, documental y de programación, sin sustituir el juicio crítico del autor ni su responsabilidad sobre las decisiones metodológicas, la interpretación de los resultados y las conclusiones presentadas. El autor responde por la coherencia del proceso, la verificación de los resultados y la integridad del contenido entregado.